

Professeur : Amor Amami

**URL de site web a scraper**

<https://duproprio.com/r>

**Objectif:**

Le but de ce pratique consistera à extraire les données ("gratter" ou "scraper") les données immobilières de la région de Québec. Pour cela, nous tenterons d'extraire les données de **Duproprio**.

**Important :**

*Ce document ne peut être utilisé dans le cadre d'une formation, publication papier, site internet ou tout support sans mon accord express.*

*Aucune reproduction, même partielle, ne peut être faite de ce document et de l'ensemble de son contenu : textes, images, etc. sans mon autorisation express. Pour toutes informations, communiquer avec moi à [aamami@big-datascience.ca](mailto:aamami@big-datascience.ca)*

Dans le cadre de ce travail, nous nous limiterons à tester s'il est possible d'extraire les données afin de pouvoir les mettre dans un fichier CSV. En effet, comme il est très probable que l'entreprise a sur son site web des conditions d'utilisations (Copyright, robot.txt) visant à restreindre ces pratiques, nous limiterons qu'à quelques pages.

**Description de l'entreprise**

Tout d'abord, il est à noter que l'entreprise est **Québécoise**. Il s'agit d'une entreprise privée qui vise à aider les vendeurs et acheteurs de faire la transaction de ventes sans l'intermédiaires de courtiers et d'agences immobilières.

**Besoin du grattage**

En tant que futur propriétaire de maison, je serais intéressé à pouvoir récupérer les informations des deux sites webs afin de pouvoir faire une analyse des habitations qui ont un prix d'aubaine et pouvoir comparer le marché immobilier.

Je sais que le prix d'une maison est fortement influencé par le marché (prix) de son quartier, sa localisation, sa superficie habitable, sa superficie de terrain, le nombre de pièces et salles de bains.

Nous essaierons d'extraire ces informations pour pouvoir consolider une liste des choix qui nous seraient les plus intéressants à nos critères factuellement.

## Début de l'extraction avec Duproprio

### Analyse des conditions d'utilisations et du "Robot.txt"

<https://duproprio.com/robots.txt>

```
User-agent: *
Disallow: /email-consent/
Disallow: /facebook/
Disallow: /file/
Disallow: /files/
Disallow: /filesystem/
Disallow: /listing/comparables/
Disallow: /listing/comparable-get-html/
Disallow: /listing/evalateur-get-html/
Disallow: /listing/modelo/
Disallow: /listing/modelo-get-html/
Disallow: /listing/print/
Disallow: /listing/print-pdf/
Disallow: /listing/report-validate-page
Disallow: /logout
Disallow: /maintenances/
Disallow: /modal/
Disallow: /modelo/
Disallow: /my-account/
Disallow: /pdf-report/
Disallow: /services/
Disallow: /unsupported-browser
Disallow: /util/
Disallow: /validate_dossier.php
Disallow: /webservice/
Disallow: /82591175/
Disallow: /9289347/
Disallow: /browse/listings/all

Allow: /*/api-proxy/infosession
Allow: /*/api-proxy/featured-homes
Disallow: /*/api-proxy

Sitemap: https://duproprio.com/sitemaps/en/index.xml.gz
Sitemap: https://duproprio.com/sitemaps/fr/index.xml.gz
```

Comme on le remarque ici, le site web permet à tous les agents mais ne permet pas de se promener avec un robot sur /browse/litings/all soit sans tous le listing des maisons.

```
{"message": "[142.118.98.193] Thanks for the visit."}
```

Nous serons donc prudent dans le choix de nos URL afin de se limiter à certaines bien spécifiques.

### Début de l'extraction de données

*#Importons ce que nous aurons de besoins*

```
from bs4 import BeautifulSoup
```

```
import requests
```

```
from os import system
```

```
from sys import exit
```

```
import time
```

```
from requests.exceptions import ConnectionError
```

```
import csv
```

```
import os
```

```
import os.path
```

In [2]:

*#Nous créerons une méthode pour récupérer précisément le contenu qui nous intéresse d'une page*

```
def extrait_contenu_page_duproprio(contenu):
```

*#Parcourons le contenu de la page*

```
soup = BeautifulSoup(contenu, "html.parser")
```

*#On sait qu'il y a un nombre défini d'annonce à récupérer. Parcourons les annonces = []*

*#On sait que les annonces sont dans les #li*

```
for rows in soup.find_all("li"):
```

```
    if (rows.has_attr('class') and "search-results-listings-list__item" in rows["class"] and "ad-zone" not in rows["class"]):
```

*#Nous sommes maintenant dans l'aperçu de l'annonce*

```
    annonce = dict()
```

*#Sortons le numéro de l'annonce*

```
    annonce['numero'] = rows.get('id')
```

*#Sortons l'URL de l'annonce*

```
    annonce['url'] = rows.find("a", class_="search-results-listings-list__item-image-link").get('href')
```

*#Sortons le montant demandé*

```
    annonce['montant_demandé'] = rows.find("h2").text.strip()
```

```

        #Sortons l'adresse
        annonce['adresse'] = rows.find("div", class_="search-results-listings-list__item-description__item search-results-listings-list__item-description__address").text.strip()

        #Ajoute tous le contenu à annonce
        annonces.append(annonce)

        #pi_terrain = 0 #span #search-results-listings-list__item-description__characteristics--long-numbers
        #pi_habitable = 0 #span #search-results-listings-list__item-description__characteristics--long-numbers #
        #nb_chambre = 0 #div #search-results-listings-list__item-description__characteristics-popover #Chambres

        #print(rows)
    return annonces

```

In [3]:

```

#Créons une autre méthode générique pour parcourir les pages qui nous intéressent.

```

```

def extrait_nombre_defini_page_duprorio(nbPages):

```

```

    baseURL = "https://duproprio.com/fr/rechercher/liste?search=true&regions%5B0%5D=3&max_price=400000&rooms=3&is_for_sale=1&with_builders=1&parent=1&sort=-published_at&pageNumber="

```

```

    #On voit dans l'URL des éléments que nous pourrions altérer pour récupérer les données soit le numéro de la page

```

```

    annonces = []

```

```

    for page in range(nbPages):

```

```

        #Composons l'URL

```

```

        URL = baseURL + str(page)

```

```

        try:

```

```

            # Nous simulerons que nous sommes Chrome

```

```

            headers = {'User-Agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/79.0.3945.130 Safari/537.36'}

```

```

            #Récupérons le contenu de cette adresse

```

```

            response = requests.get(URL, headers=headers)

```

```

            #Extrayons le contenu et ajoutons le à un array

```

```

    annoncesRecues = []
    annoncesRecues = extrait_contenu_page_duproprio(response.text)

    annonces += annoncesRecues

    #On va donner à notre algorithme une pause tactique pour éviter d
e surcharger la source
    time.sleep(3)

    except requests.exceptions.RequestException as e:
        print(e)
        exit()

    return annonces

```

In [4]:

```

#Commençons par une page et décortiquons l'URL

#On voit aussi que nous avons déjà contrôlé notre recherche afin de se limite
r à 5 pages
    annonces = []
    annonces = extrait_nombre_defini_page_duproprio(3)

#Nous pourrions afficher les résultats ici
    #print(annonces)

#Écrivons maintenant le résultat dans un CSV
    colonneDuCSV = annonces[0].keys()
    with open('recherche_duProprio.csv', 'w') as output_file:
        dict_writer = csv.DictWriter(output_file, fieldnames=colonneDuCSV)
        dict_writer.writeheader()
        dict_writer.writerows(annonces)

#Le fichier devrait se trouver dans le répertoire d'exécution de ce fichier P
ython
#Dans le fichier "recherche_duProprio.csv"

```